

Podstawy statystyki praktycznej

Lista 1 - Podstawowe statystyki

Zadanie 1: Zbiór danych *grades.txt* zawiera dane 78 uczniów siódmej klasy pewnej szkoły w USA. Dla każdego ucznia mamy informację o średniej ocen (ocenom *F*, *D*−, *D*, *D*+, *C*−, *C*, *C*+, *B*−, *B*, *B*+, *A*−, *A*, odpowiadają liczby od 0 do 11), wynik standardowego testu IQ, płeć oraz punktację na teście psychologicznym (*Piers-Harris Children's Self-Concept Scale*).

- (a) Oblicz wartości podstawowych statystyk (średnia, mediana, kwartyle, minimum, maksimum, wariancja, odchylenie standardowe, współczynnik zmienności) dla zmiennych ilościowych: ŚrOc, IQ, PH. Wyniki podaj w tabeli. Jakie wnioski co do danych można wyciągnąć na podstawie obliczonych statystyk?
- (b) Narysuj histogram oraz boxplot dla każdej zmiennej ilościowej. Jakie wnioski co do danych można wyciągnąć na podstawie wykresów?
- (c) Powtórz punkty (a),(b) osobno dla chłopców i dla dziewcząt. Na podstawie obliczonych statystyk oraz wykresów porównaj ŚrOc, IQ, PH dla chłopców i dziewcząt.
- (d) Dla wybranej zmiennej ilościowej narysuj 5 histogramów dla kilku różnych liczb klas (bardzo mała, mała, średnia, duża, bardzo duża). Skomentuj jaki efekt otrzymujemy wybierając zbyt mało klas, a jaki efekt, gdy wybieramy zbyt dużo klas. Jaka liczba klasów jest optymalna i dlaczego?

Zadanie 2: Zbiór danych *income.dat* zawiera wyniki ankiet dotyczących zarobków przeprowadzonych w roku 2000 przez *Bureau of Labor Statistics* na reprezentatywnej próbie 55899 mieszkańców USA. Dla każdej osoby podany jest wiek (w latach), wykształcenie (1 = podstawowe, 2 = niepełne średnie, 3 = średnie, 4 = niepełne wyższe, 5 = wyższe (licencjat), 6 = wyższe (magisterium)), płeć (1 = mężczyzna, 2 = kobieta), roczne zarobki (w dolarach) oraz sektor zatrudnienia (5 = sektor prywatny, 6 = sektor publiczny, 7 = samozatrudnienie).

W oparciu o podane dane, wykorzystując narzędzia poznane na wykładzie:

- (a) W oparciu o podstawowe statystyki oraz wykresy opisz strukturę zarobków mieszkańców USA w roku 2000. Skomentuj występowanie w danych ujemnych zarobków.

- (b) Porównaj zarobki w zależności od poziomu wykształcenia.
- (c) Czy na podstawie tych danych można stwierdzić, że mężczyźni mieli wyższe zarobki niż kobiety (w USA w 2000 roku)? Odpowiedź uzasadnij.
- (c) wyznacz „przeciętne” zarobki mieszkańców USA w roku 2000, przyjmując jakąś definicję „przeciętnych zarobków” i wyjaśniając jakie argumenty stoją za takim wyborem. Porównaj otrzymany wynik ze średnią i medianą.